

Analiza NLP a Fenomenului de Code-Switching (Surzhyk) în Social Media: Identificare la Nivel de Token

Deliu Georgiana
georgiana.deliu@s.unibuc.ro

Universitatea din București, Facultatea de Matematică și Informatică

Rezumat

Această lucrare explorează detectarea și analiza fenomenului de code-switching ucraineano-rus, cunoscut sub numele de Surzhyk, folosind tehnici de Natural Language Processing (NLP). Analiza se concentrează pe date extrase din rețelele de socializare, pregătite și adnotate la nivel de token. Prin Analiza Exploratorie a Datelor (EDA) s-au identificat tipare morfologice specifice cuvintelor hibride, demonstrând o lungime și o complexitate silabică mai mare. Lucrarea evaluează modele NLP clasice (spaCy) și modele bazate pe arhitectura Transformer (XLM-RoBERTa), evidențiind fenomenul de supra-tokenizare ca un indicator cheie pentru interferențe. De asemenea, lucrarea testează limitările modelului pre-antrenat ParlLangID-UA-RU, justificând necesitatea unui fine-tuning personalizat care să includă o clasă dedicată cuvintelor mixte.

1 Introducere

În societățile multilingve, folosirea alternativă a mai multor limbi în cadrul aceluiași discurs, fenomen cunoscut sub numele de code-switching sau code-mixing, reprezintă o provocare unică pentru procesarea limbajului natural (NLP). Ucraina este un exemplu notabil de limbă frecvent implicată în astfel de scenarii de code-switching alături de limba rusă. Această combinație hibridă este colocvial denumită *Surzhyk*.

Asemănarea dintre aceste limbi și utilizarea alfabetului chirilic în ambele sisteme ortografice complică masiv sarcina modelelor NLP, ducând la multe cazuri în

care cuvintele sunt scrise identic, în ciuda diferențelor fonetice clare. Deși există cercetări recente privind identificarea limbii la nivel de token pentru documente parlamentare ucrainene [1], s-a constatat că în transcrierile formale cuvintele hibride reprezintă doar 0.29% din setul de date, determinând cercetătorii să excludă categoria mixtă („MIX”) din modelul lor de clasificare final.

Totuși, în contextul comunicării informale din social media, interferențele intra-cuvânt (de exemplu, o rădăcină rusească declinată conform morfologiei ucrainene) sunt abundente. Scopul acestei lucrări este de a pregăti și analiza un set de date specific pentru social media, evaluând limitele abordărilor curente (inclusiv modelele de Part-of-Speech tagging și modelele Transformer bazate pe sub-tokenizare) în fața acestui limbaj mixt.

2 Metodologie și Pregătirea Datelor

Primul pas al cercetării a constat în pregătirea unui corpus de 488 de propoziții extrase din social media, având un grad ridicat de interferență. Pentru a permite o adnotare riguroasă la nivel de token a claselor OOV (Out of Vocabulary / Surzhyk), datele au fost procesate și anonimizate pentru a fi compatibile cu platforma de etichetare Labelbox.

Codul Python de mai jos (Listarea 1) demonstrează procesul de transformare a datelor dintr-un format CSV brut într-un format JSON secvențial. Identificatorii utilizatorilor au fost excluși intenționat, generându-se identificatori externi (prop_1, prop_2), pentru a concentra analiza exclusiv asupra textului.

```
import csv
import json

fisier_intrare = "surzhyk_toxicity.csv"
fisier_csv_iesire = "doar_propozitii.csv"
fisier_json_iesire = "import_adnotare.json"
date_json = []

with open(fisier_intrare, "r", encoding="utf-8") as f_in, \
    open(fisier_csv_iesire, "w", encoding="utf-8", newline='') \
    as f_csv:
    reader = csv.reader(f_in)
    writer = csv.writer(f_csv)
    header = next(reader, None)
    writer.writerow(["Propozitie_Originala"])

    for i, rand in enumerate(reader):
        if not rand:
            continue
        propozitie = rand[0]
```

```

writer.writerow([propozitie])
date_json.append({
    "row_data": propozitie,
    "external_id": f"prop_{i+1}"
})

with open(fisier_json_iesire, "w", encoding="utf-8") as f_json:
    json.dump(date_json, f_json, ensure_ascii=False, indent=4)

```

Listing 1: Script pentru pregătirea și anonimizarea datelor pentru platforma Labelbox.

3 Analiza Exploratorie a Datelor (EDA)

Analiza morfologică a cuvintelor strict rusești (RU) comparativ cu elementele de tip Surzhyk sau Out-Of-Vocabulary (OOV) a dezvăluit diferențe structurale majore. Fenomenul de hibridizare are adesea loc în interiorul cuvântului, combinând, de exemplu, o rădăcină rusească cu o terminație ucraineană.

Conform analizei pe setul nostru de date, cuvintele strict rusești folosite ca elemente de legătură sunt predominant scurte, având o lungime medie de 4.51 caractere și 1.81 silabe. În contrast, cuvintele de tip Surzhyk sunt vizibil mai complexe, având o lungime medie de 6.85 caractere și 2.79 silabe (Tabelul 1). Această creștere a lungimii confirmă dominanța fuzionării rădăcinilor lexicale rusești cu afixe (prefixe și sufixe) din limba ucraineană.

Tabela 1: Analiza morfologică a elementelor de Code-Switching.

Categoria Lexicală	Lungime Medie (caractere)	Silabe Medii
Cuvinte Strict Rusești (RU)	4.51	1.81
Cuvinte Hibride / Surzhyk (OOV)	6.85	2.79

De asemenea, analiza a extras cele mai lungi secvențe continue de code-switching inter-propozițional, arătând fragmente întregi (până la 11 cuvinte consecutive) în care structura limbii se schimbă complet înainte de a reveni la ucraineană.

4 Limitări ale Modelelor NLP Clasice (spaCy)

Pentru a stabili o linie de bază (baseline), am evaluat un model clasic de procesare a limbajului antrenat pe limba ucraineană standard (uk_core_news_sm din biblioteca spaCy). Modelul a fost testat pe o propoziție hibridă: „А мальчик навпроти мене наблюдавав повний пакет і на маму слегка”.

Rezultatele au confirmat că taggerile Part-of-Speech (POS) eșuează sistematic în cazul termenilor Surzhyk. Deoarece elemente precum „*наблював*” sau „*наکم*” au rădăcini necunoscute vocabularului ucrainean standard, modelul forțează analize sintactice greșite, bazându-se doar pe euristici de sufixare.

5 Tokenizarea BERT și Supratokenizarea

Modelele contemporane de limbaj profund (Transformer), precum XLM-RoBERTa [conneau2019unsupervised], bazat pe arhitectura introdusă de BERT [devlin2019bert], folosesc tokenizarea la nivel de sub-cuvânt (sub-word tokenization) folosind algoritmi precum Byte-Pair Encoding (BPE). Aceasta ridică o nouă problemă în analiza Surzhyk.

Am comparat procesul de tokenizare între cuvinte literare ucrainene și corespondentele sau echivalentele lor în argoul Surzhyk, având lungimi similare. Rezultatele (Tabelul 2) indică un fenomen clar de **supratokenizare** a argoului.

Tabela 2: Comparația tokenizării sub-word: Literar vs. Surzhyk.

Termen	Tokeni rezultați (XLM-RoBERTa)	Total
Literar: роблю	['_ ', ' ']	2
Surzhyk: факаплю	['_ ', ' ', ' ', ' ']	3
Literar: дівчина	['_ ']	1
Surzhyk: дефка	['_ ', ' ', ' ', ' ', ' ']	4
Literar: вимовою	['_ ', ' ', ' ', ' ']	3
Surzhyk: проізношенієм	['_ ', ' ', ' ', ' ', ' ', ' ', ' ', ' ']	5

Cuvintele standard sunt procesate într-unul sau doi tokeni, în timp ce formațiunile mixte sunt sparte în 3-5 fragmente, asemenea unui puzzle dezmembrat. Deși acest comportament fragmentează sensul lexical, din perspectiva antrenării unei rețele neurale, acest tipar anormal de fragmentare devine o caracteristică extrem de utilă (un semnal) pentru detectarea automată a interferențelor în faza de *fine-tuning*.

6 Evaluarea Modelului ParLLangID-UA-RU

Pentru identificarea limbii la nivel lexical pe date mixte, un punct de referință recent este modelul ParLLangID-UA-RU, dezvoltat pe transcrierile Parlamentului ucrainean [1]. Experimentele anterioare sugerează că arhitecturile de tip BERT prezintă performanțe promițătoare pentru această sarcină.

Totuși, evaluarea modelului pre-antrenat Kanishcheva pe dataset-ul nostru informal de social media relevă limitări fundamentale. Autorii studiului precizează că, din cauza distribuției slabe a datelor hibride în discursul parlamentar oficial, cuvintele hibride ruso-ucrainene au reprezentat doar 0.29% din corpul lor [1]. În consecință, autorii au decis excluderea completă a categoriei MIX din arhitectura clasificatorului final.

Când modelul este aplicat pe propoziția de test din social media („*А мальчик навпроти мене наблюдав повний пакет і на маму слезка*”), el forțează o decizie binară (Rusia vs. Ucraina) pentru fiecare token hibrid. Din cauza lipsei unei clase specifice pentru argou, modelul produce erori clasificatoare forțate. Această observație confirmă o ipoteză centrală a lucrării de față: identificarea exactă a dialectelor hibride pe internet necesită un model antrenat explicit pe date adnotate cu o clasă dedicată interferențelor (precum MIX sau Surzhyk).

7 Considerații Finale

Analiza fenomenului de code-switching (Surzhyk) din social media necesită o abordare diferită de cea aplicată textelor formale. EDA a relevat că structurile hibride sunt semnificativ mai complexe morfologic decât lexicul împrumutat standard. De asemenea, s-a demonstrat că modelele NLP clasice (spaCy) și modelele token-classification lipsite de categoria mixtă (precum ParlLangID) nu pot procesa eficient acest limbaj.

În viitor, soluția optimă implică utilizarea fenomenului observat de supratokenizare în modele tip BERT ca semnal pentru un *fine-tuning* dedicat. Setul de date anonimizat și adnotat la nivel de token pe platforma Labelbox va servi ca fundament pentru antrenarea unui model care să recunoască nativ clasa de interferențe Surzhyk.

Bibliografie

- [1] Olha Kanishcheva, „ParlLangID-UA-RU: A Model for Language Identification in Code-Switched Ukrainian-Russian Contexts”, în **Hugging Face Repository** (2026), URL: <https://huggingface.co/OKanishcheva/ParlLangID-UA-RU>.